

FedWatch AI：基于多智能体编排的美联储政策预测系统

作者：余青锋

提交日期：2026-06-21

代码仓库：<https://github.com/MessiahYu/fed-agent-project>
(<https://github.com/MessiahYu/fed-agent-project>)

一、项目概述

1.1 项目目标

本项目搭建一个**基于多智能体编排的持续性经济事件预测系统**，预测美联储（Fed）议息会议的政策走向（加息 / 降息 / 维持不变）。

核心思路是将四路异质信号（LLM 语义分 + VAR 计量模型 + 市场信号 + 政治压力信号）融合，通过网格搜索在历史数据上确定最优权重，再对一个**完全未参与训练的最终测试集（2025-01 至 2026-06，共 12 次 FOMC 会议）**进行独立评估，以此验证模型的泛化能力。

这 12 次会议横跨鲍威尔（Powell）主席晚期和沃什（Warsh）新任主席期，涵盖降息周期启动（2025 年底）与政策不确定性最高阶段（2026 年）。最终 V5 版本在 12 次中预测正确 11 次，准确率 **91.7%**。且准确预测了三次降息决定中的两次。


1.2 项目要求完成情况

项目要求	完成情况
数据自动化感知智能体	✅ 自动抓取美联储官网声明（2000-至今）+ FRED API 实时宏观数据
语义特征提取智能体	✅ DeepSeek LLM 批量分析 217 次声明，输出可量化鹰鸽分（hawkish_score）
决策推演智能体	✅ VAR 计量模型 + 四路信号融合 + 网格搜索权重优化（6012 组参数）
数据触发→滚动预测→风险归因闭环	✅ 每次新会议自动触发更新、分析、融合、预测全链路
内生性 / 因果识别论证	✅ 走一步 VAR 严格防前视偏差，各信号独立构建避免联立内生性
证据链可解释性	✅ 每次预测输出 key_evidence（关键证据条目）+ 信号逐项拆解
沃什政策脉络推理	✅ 2026-06-17 首次会议分析（措辞偏鹰但全票维持，矛盾性分析）

1.3 多智能体框架：CrewAI

本系统基于 **CrewAI** 框架搭建多智能体编排，而非 LangChain 或 AutoGen。

选择 CrewAI 的理由： - 原生支持 **Role-Goal-Backstory** 角色设定，每个智能体有明确分工和行为约束 - 内置任务依赖链（Task → Crew），天然适合“数据→分析→决策”的流水线结构 - 支持结构化输出（output_pydantic），保证信号数值可直接参与下游计算



1.4 机器学习组件分类

模块	ML 类别	具体方法
权重优化（网格搜索）	有监督学习	以历史 FOMC 决策为标签，在训练集上穷举 6012 个参数组合，最大化分类准确率
VAR 走一步预测	有监督学习（时序）	向量自回归预测下期联邦基金利率方向，走一步无前视偏差
LLM 语义分析	零样本推理（迁移学习）	DeepSeek 基于预训练知识，无需额外标注样本对 FOMC 声明进行鹰鸽打分
政治压力信号	无监督特征工程	EPU / VIX 滚动百分位计算，不使用任何决策标签

二、最终版本 V5 模型详解

V5 是本项目方法论最完整的版本，同时修复了前序版本中存在的两个核心问题：**时间固定效应**（V3 修复）与**同期信息泄露**（V4 修复）。

2.1 核心预测公式

四路信号融合：

fusion_score = 0.40 × LLM语义分（上次声明）

+ 0.35 × VAR计量信号

+ 0.10 × 市场信号

+ 0.15 × 政治压力信号

决策规则：

fusion_score > +0.35 → 预测 HIKE（加息）

fusion_score < -0.40 → 预测 CUT（降息）

其余 → 预测 HOLD（维持不变）

注意：LLM 语义分使用的是上一次 FOMC 会议声明提取的鹰鸽分，而非当次声明。原因详见第三章 V4 节。

2.2 各信号数据来源与计算逻辑

信号	数据来源	计算逻辑	时间对齐
LLM 语义分	美联储官网 FOMC 声明原文	DeepSeek 输出 -1.0（极鸽）到 +1.0（极鹰）	使用上次声明分数（shift(1)）
VAR 计量信号	FRED: FEDFUNDS / CPI / UNRATE	走一步 VAR，截断到会议前 2 天	无前视偏差
市场信号	FRED: DGS2 / DGS10	收益率曲线斜率（10Y-2Y）→ hike / hold / cut	会议前数据
政治压力	FRED: EPU 指数 / VIX	滚动 36 月百分位加权，映射到 [-1, +1]	月频当期值

2.3 V5 最优参数（网格搜索结果）

参数	V5 值	含义
w_llm	0.40	LLM 语义信号权重
w_var	0.35	VAR 计量信号权重
w_market	0.10	市场信号权重
w_pol	0.15	政治压力信号权重
hike_thr	+0.35	判断加息的融合分门槛
cut_thr	-0.40	判断降息的融合分门槛
训练集准确率	82.7%（162次）	历史 2000-2024 随机 80%
测试集准确率	66.7%（42次）	历史 2000-2024 随机 20%，基线 64.3%

2.4 V5 最终测试集逐次预测（2025-01 至 2026-06）

会议日期	主席	LLM分(上次)	VAR	V5融合分	V5预测	实际	结果
2025-01-29	Powell	+0.10	CUT	-0.361	HOLD	HOLD	✓

会议日期	主席	LLM分(上次)	VAR	V5融合分	V5预测	实际	结果
2025-03-19	Powell	+0.10	HOLD	-0.083	HOLD	HOLD	✓
2025-05-07	Powell	+0.15	HOLD	-0.051	HOLD	HOLD	✓
2025-06-18	Powell	+0.30	HOLD	+0.037	HOLD	HOLD	✓
2025-07-30	Powell	+0.20	HOLD	+0.019	HOLD	HOLD	✓
2025-09-17	Powell	-0.20	HOLD	-0.115	HOLD	HOLD	✓
2025-10-29	Powell	-0.55	HOLD	-0.288	HOLD	CUT	X
2025-12-10	Powell	-0.35	CUT	-0.506	CUT	CUT	✓
2026-01-28	Powell	-0.35	CUT	-0.566	CUT	CUT	✓
2026-03-18	Powell	+0.05	HOLD	-0.106	HOLD	HOLD	✓
2026-04-29	Powell	+0.15	HOLD	-0.011	HOLD	HOLD	✓
2026-06-17	Warsh	-0.25	HOLD	+0.050	HOLD	HOLD	✓

V5 准确率：91.7% (11/12)，超越基线 (75%) +16.7pp

2.5 政策转折点识别能力

75% 的原始准确率存在误导性——12 次会议中 9 次是 HOLD，“永远猜维持”的零智能基线同样是 75%。真正的模型价值在于能否识别政策转变节点（3 次 CUT 事件）：

降息事件	基线	V2	V3	V4	V5
2025-10-29 CUT	HOLD X	HOLD X	HOLD X	HOLD X	HOLD X
2025-12-10 CUT	HOLD X	CUT ✓	CUT ✓	CUT ✓	CUT ✓
2026-01-28 CUT	HOLD X	HOLD X	CUT ✓	CUT ✓	CUT ✓
CUT 召回率	0%	33%	67%	67%	67%

从 V2 的 33% 到 V3/V4/V5 的 67%，系统在 3 次实际降息中能够提前发出 2 次预警信号，而基线策略永远无法捕捉政策转变。

2.6 三个准确率的解读（训练 82.7% > 最终 91.7% > 历史测试 66.7%？）

三个数字乍看矛盾，实际上各有成因：


历史测试集最低（66.7%，42 次） 是最可信的泛化估计。它通过分层随机抽样覆盖 2000-2024 年所有经济周期——零利率时代、金融危机、COVID 冲击——一组固定权重很难同时适应如此多样的环境，尤其加息（HIKE）召回率只有 37.5%，暴露了模型在非典型时期的局限。

最终测试集偏高（91.7%，12 次） 有三点结构性原因：① 12 次会议中 9 次是 HOLD（占 75%），类别高度集中，基线本身就是 75%；② 2025-2026 年与训练数据中最近的 2021-2024 年市场特征最相近，信号更清晰；③ 样本仅 12 个，统计置信区间极宽（约 ±15pp），单次运气成分不可忽视。

结论：历史测试集的 66.7% 是更保守、更诚实的跨周期泛化能力估计；最终测试集的 91.7% 反映近期特定市场环境下的实战表现。模型真实能力大概在两者之间，且对近期降息周期的适应性优于历史极端时期。

三、五代迭代过程

3.1 迭代全貌：树状图



3.2 箭头①：V1 → V2（从实时到系统，从定性到全量化）

V1 的局限：V1 是一次性实时预测系统，每次运行只分析当前一次会议，没有历史验证，无法量化模型的真实预测能力。权重全靠人工设定，缺乏数据驱动的依据。

V2 做了什么：

改进项	具体内容
历史批量分析	从美联储官网自动抓取 2000-至今 217 次声明，全部过 LLM 打分，存入数据库
四路全量化	LLM 分、VAR 信号、收益率曲线市场信号、EPU/VIX 政治压力信号全部数值化
网格搜索	遍历 6012 个合法权重/阈值组合，在训练集上以准确率最大化为目标自动寻优
三表数据库	fomc_history（会议记录）+ semantic_history（LLM语义）+ political_quant_monthly（月频宏观）
走一步 VAR	每次预测只用会议前 2 天截止的宏观数据，严格无前视偏差

背后原理：多信号融合的动机来自**没有任何单一信号全能**的事实。LLM 能读文字但不了解历史统计规律；VAR 懂数字但看不懂措辞变化；市场利率反映集体预期但有时滞后；政治压力捕捉尾部风险但信噪比低。四路融合，取长补短。

3.3 箭头②：V2 → V3（修复时间固定效应）

V2 的问题：时间固定效应（Time Fixed Effects）

V2 将 2000-2020 作为训练集，2021-2024 作为测试集。这带来一个系统性偏差：

V2 测试集（2021-2024）全部处于疫后高通胀 + 快速加息周期

- 该时期 HIKE 样本多，HOLD 基线仅 56.2%
- 测试集"相对容易"，超越基线幅度（+9.4pp）被虚高
- 模型可能只学到了"加息期的判断逻辑"，而非普遍规律

这个现象在计量经济学中称为**时间固定效应**：相邻年份的会议因共享同一宏观背景（如 2022-2023 的高通胀共识），在统计上并非独立同分布。

V3 的修复：分层随机 80/20 抽样

全部 206 次历史会议（2000-2024）

↓

按 HOLD / HIKE / CUT 三类分别独立随机打乱（seed=42）

↓

各类前 80% → 训练集（165次）
各类后 20% → 测试集（41次）

↓

训练集和测试集各自均匀覆盖所有经济周期
（互联网泡沫、金融危机、零利率时代、加息周期.....）

逻辑依据来自**随机对照实验 (RCT)** 的精神：通过随机分配，使两组在所有可观测和不可观测特征上分布一致，从而排除“所处时代”这一混淆变量。

代价：V3 随机打乱后，相邻两行可能对应 2003 年和 2018 年的会议，因此无法直接做“上一次会议”的滞后操作——这个限制在 V5 中得到解决。

3.4 箭头③：V2 → V4（修复同期信息泄露）

V2/V3 存在的根本性问题：同期信息泄露 (Contemporaneous Leakage)

V2 和 V3 均使用**当次 FOMC 声明**的鹰鸽分来预测**当次会议**的利率决策。这在逻辑上是有**巨大缺陷**的：

关键事实：FOMC 声明原文与利率决策在同一时刻（美东时间下午 2:00）对外公布

也就是说，声明文本和决策结果是同一决策过程的两个输出，
用当次声明来“预测”当次决策，在现实中根本不可操作——
因为在决策公布之前，你根本拿不到声明原文。

这相当于用一个人出门后的穿搭（声明）来“预测”他出门前就已经决定的行程（决策）。

V4 的修复：LLM 信号滞后一期 (shift(1))

V2/V3 逻辑（存在泄露）：

第 N 次声明（鹰鸽分）→ 预测第 N 次决策 X

V4 修复后：

第 N-1 次声明（鹰鸽分）→ 预测第 N 次决策 ✓ 真正前瞻

代码层面只有三行改动：

```
for col in ["hawkish_score", "inflation_concern", "growth_concern"]:  
    df[col] = df[col].shift(1)    # 整体后移一期  
df = df.dropna(subset=["hawkish_score"])    # 丢弃第一行（无前驱）
```

经济直觉：FOMC 政策具有路径依赖（forward guidance）。上次声明的措辞变化是当前政策立场的“领先指标”——鸽派措辞的积累，往往预告了下次行动方向。

效果：V4 在最终测试集（12次）准确率从 75% 跃升至 91.7%，其中最典型的修正是：

2026-06-17 沃什首次会议——V2/V3 读取沃什本人鹰派声明（+0.15）后误判 HIKE；V4 使用上次鲍威尔的鸽派声明（-0.25），融合分 -0.012，正确预测 HOLD。

代价：V4 沿用 V2 的时间切割，历史测试集集中在 2021-2024 加息周期，测试准确率（87.5%）有所虚高。

3.5 箭头④：V3 + V4 → V5（两项修复同时生效）

V5 要解决的问题：根据控制变量的思想，V3 和 V4 各解决了一个问题，且这两个问题都独立地表明能够有助于提高模型的预测精度。但能不能同时解决这两个问题？

障碍在于：两步操作**顺序不能颠倒**。

- ✖

错误顺序（先随机打乱再滞后）：
随机打乱后：2003年 | 2018年 | 2007年 | ...
shift(1) 后："上一次" = 毫无关联的另一年会议，失去经济含义
- ✓

正确顺序（先滞后再打乱）：
Step 1: 按时间顺序计算 shift(1) — 每次会议的 lag 特征锁定为真实的时间前驱
Step 2: 做分层随机 80/20 划分 — 只影响哪些行进训练/测试，不改变 lag 值

关键洞察：滞后特征是**特征工程步骤**，必须在划分之前在时间顺序上完成。一旦 lag 特征被锁定在每条记录里，后续的随机划分不会破坏它的经济含义。

V5 的历史测试集（42次，随机 20%，跨 2000-2024）准确率为 66.7%（基线 64.3%，+2.4pp），这是两项修复都生效后更诚实的泛化评估——V4 历史测试集 87.5% 中有相当部分来自时代偏差，真实泛化优势约在 +2-3pp 量级。

四、五版本全面性能对比

4.1 各版本方法论定位

维度	V1	V2	V3	V4	V5
系统类型	实时单次	历史批量	历史批量	历史批量	历史批量
LLM 特征时序	当次声明（泄露）	当次声明（泄露）	当次声明（泄露）	上次声明（已修复）	上次声明（已修复）
历史划分方式	无	时间切割	分层随机（已修复）	时间切割	分层随机（已修复）
同期信息泄露	存在	存在	存在	已消除	已消除
时间固定效应	不涉及	存在	已消除	存在	已消除
评估可信度	无历史统计	中（时代偏差）	高（随机无偏）	中（时代偏差）	高（随机无偏）

4.2 最优权重演变

参数	V1（人工）	V2	V3	V4	V5	变化规律解读
w_llm	~0.40	0.45	0.35	0.45	0.40	V3降低因多周期VAR更稳；V4恢复因lag特征更干净
w_var	~0.30	0.20	0.35	0.30	0.35	覆盖多周期后VAR计量价值凸显
w_market	~0.15	0.15	0.10	0.15	0.10	相对稳定

参数	V1 (人工)	V2	V3	V4	V5	变化规律解读
w_pol	~0.15	0.20	0.20	0.10	0.15	V4/V5 滞后 LLM已隐含政策氛围，政治信号边际价值降低
hike_thr	~+0.30	+0.25	+0.20	+0.35	+0.35	滞后信号衰减，需更高阈值触发HIKE预测
cut_thr	~-0.30	-0.35	-0.35	-0.35	-0.40	V5 更严格，减少误判

4.3 历史测试集性能对比

注：V3 和 V5 采用分层随机划分，结果更具可比性；V2 和 V4 的历史测试集集中在 2021-2024，基线更低，数值偏高。

版本	历史测试集	样本数	基线	准确率	超基线	评估质量
V2	2021-2024 (时间切割)	32次	56.2%	65.6%	+9.4pp	偏高（时代偏差）
V3	随机 20%，跨 2000-2024	41次	65.9%	65.9%	+0.0pp	诚实无偏
V4	2021-2024 (时间切割)	32次	56.2%	87.5%	+31.3pp	偏高（时代偏差）
V5	随机 20%，跨 2000-2024	42次	64.3%	66.7%	+2.4pp	诚实无偏

V4 的 87.5% 须谨慎解读：测试集全部落在 2021-2024 加息周期，宏观信号极其清晰。V5 在相同 lag 特征下（方法论等价），诚实测试集准确率仅为 66.7%，说明 V4 中约 20pp 来自时代偏差而非模型能力。

4.4 最终测试集性能对比（2025-01 至 2026-06，12次，全程封存，不存在数据泄露和数据污染）

版本	准确率	超基线	CUT 召回率	关键特征
基线（永远HOLD）	75.0%	—	0/3（0%）	无预测能力
V2	75.0%（9/12）	+0.0pp	1/3（33%）	时间切割+同期LLM
V3	75.0%（9/12）	+0.0pp	2/3（67%）	随机划分+同期LLM
V4	91.7%（11/12）	+16.7pp	2/3（67%）	时间切割+滞后LLM

版本	准确率	超基线	CUT 召回率	关键特征
V5	91.7% (11/12)	+16.7pp	2/3 (67%)	随机划分+滞后LLM

V4 和 V5 在最终测试集上 12 次预测完全一致——这说明**LLM 滞后特征**（而非权重调整）才是驱动准确率从 75% 跃升至 91.7% 的核心因素。

4.5 最终测试集逐版本逐次对比

会议日期	实际	V2	V3	V4	V5
2025-01-29	HOLD	✓ HOLD	✗ CUT	✓ HOLD	✓ HOLD
2025-03-19	HOLD	✓ HOLD	✓ HOLD	✓ HOLD	✓ HOLD
2025-05-07	HOLD	✓ HOLD	✓ HOLD	✓ HOLD	✓ HOLD
2025-06-18	HOLD	✓ HOLD	✓ HOLD	✓ HOLD	✓ HOLD
2025-07-30	HOLD	✓ HOLD	✓ HOLD	✓ HOLD	✓ HOLD
2025-09-17	HOLD	✓ HOLD	✓ HOLD	✓ HOLD	✓ HOLD
2025-10-29	CUT	✗ HOLD	✗ HOLD	✗ HOLD	✗ HOLD
2025-12-10	CUT	✓ CUT	✓ CUT	✓ CUT	✓ CUT
2026-01-28	CUT	✗ HOLD	✓ CUT	✓ CUT	✓ CUT
2026-03-18	HOLD	✓ HOLD	✓ HOLD	✓ HOLD	✓ HOLD
2026-04-29	HOLD	✓ HOLD	✓ HOLD	✓ HOLD	✓ HOLD
2026-06-17	HOLD	✗ HIKE	✗ HIKE	✓ HOLD	✓ HOLD
正确数		9/12 (75%)	9/12 (75%)	11/12 (91.7%)	11/12 (91.7%)

两次关键修正： - **2026-01-28**：V2 用当次声明（+0.05，偏鹰）误判 HOLD；V4/V5 用上次 12 月鸽派声明（-0.35），正确判 CUT - **2026-06-17**：V2/V3 用沃什本人鹰派声明（+0.15）误判 HIKE；V4/V5 用上次鲍威尔鸽派声明（-0.25），正确判 HOLD

4.6 行业水平对标

预测方法	准确率参考	备注
CME FedWatch（期货市场）	85-95%	会议前 1 周，融合全市场信息
华尔街经济学家共识	78-85%	大型团队 + 实时数据 + 人工判断
学术 ML / NLP 模型	65-80%	本系统直接可比基准
本系统 V5（最终测试集）	91.7%（12次）	处于学术 ML 上沿，接近市场共识水平
本系统 V5（历史测试集，无偏估计）	66.7%	诚实的跨周期泛化能力

注意：最终测试集 12 次样本量较少，置信区间约 $\pm 25\%$ ，91.7% 的点估计须谨慎外推。历史测试集 42 次（随机无偏）的 66.7% 更接近系统真实的长期泛化能力，处于学术 ML 模型的中位水平。

五、现有不足与后续改进方向

5.1 同一漏判的根源：信号还不够早

三次降息中唯一漏判的是 **2025-10-29**，融合分 -0.288，距阈值 -0.40 差 0.112。LLM 分已经达到 -0.55（非常鸽），但 VAR 和市场信号仍显示 HOLD，拉高了融合分。

本质原因：VAR 是基于 FEDFUNDS / CPI / UNRATE 的 72 个月滚动窗口，反映的是宏观数据的历史趋势，对突然的“转向意愿”不够敏感。可能的改进方向：- 引入 $\Delta\text{hawkish}$ （鹰鸽分变化量）作为额外特征，捕捉措辞趋势加速 - 以 **Macro F1** 而非 Accuracy 为优化目标，迫使模型更重视少数类 CUT

5.2 新主席上任期建模不足

沃什 2026-05-22 上任，目前仅有 1 次会议记录（2026-06-17），样本严重不足。V1 的“主席行为蒸馏”智能体因数据稀少而效果有限。

改进方向：对 12 位 FOMC 投票委员分别建立鹰鸽立场画像，通过委员分歧程度（SEP 点阵图离散度）预测集体决策的不确定性。

5.3 样本量与评估稳健性

12 次最终测试集中每次预测正确与否影响准确率 8pp，统计置信区间偏宽。理想状态是持续运营——每次 FOMC 会议后自动并入数据库，最终测试集随时间自然增长，评估结果趋于稳定。

5.4 宏观数据时效性

FRED 数据存在 1-2 个月滞后（CPI 为上月数据）。可引入高频替代数据（商品期货、信用卡消费、Google 搜索指数）和实时新闻情绪指数，替换发布滞后的月度指标。

5.5 寻找工具变量以解决内生性问题

在现有的框架下，美联储表态、经济数据和市场信号等变量间不可避免的仍然存在内生性问题。接下来可以考虑巧妙地引入工具变量来解决模型的内生性问题。

文档版本：v5-dev 分支，基于 美国东部时间 2026-06-21 最新运行结果